
Rapport d'Analyse du Dataset

Scraping des images d'Oiseaux e

Espèces étudiées

- Hibou grand-duc
- Flamant rose
- Martin-pêcheur
- Cygne tuberculé
- Pic vert

Module : Application IA — Semestre 6
Projet : Scrapind des images — Constitution d'un dataset d'images
Date : Mai 2026

Table des matières

1	Vue d'ensemble du pipeline	2
2	Statistiques de collecte (avant nettoyage)	2
2.1	Nombre d'images collectées par espèce	2
2.2	Visualisation — Images collectées par espèce	2
3	Statistiques de nettoyage	3
3.1	Tableau récapitulatif par espèce	3
3.2	Répartition des suppressions par motif	3
3.3	Visualisation — Suppressions par espèce et motif	4
4	Prétraitement et augmentation	4
4.1	Pipeline de prétraitement	4
4.2	Stratégie d'augmentation	4
4.3	Nombre d'images après augmentation	5
4.4	Visualisation — Avant/après augmentation	5
5	Répartition finale Train / Validation / Test	5
6	Analyse critique des biais potentiels	6
6.1	Origine géographique des images	6
6.2	Diversité des conditions de prise de vue	6
6.3	Disponibilité relative des espèces	7
6.4	Biais de confirmation	7
7	Respect des droits et aspects légaux	7
7.1	Sources des images	7
7.2	Cadre légal applicable	7
8	Synthèse	8

1 Vue d'ensemble du pipeline

Le dataset a été constitué en quatre étapes successives :

1. **Scraping** : collecte automatique d'images via Bing Images (Selenium + Requests).
2. **Nettoyage** : suppression des images corrompues, trop petites, dupliquées ou filigranées.
3. **Prétraitement** : redimensionnement à 224×224 px, conversion en JPEG, normalisation $[0, 1]$.
4. **Augmentation** : génération de 5 variantes par image (rotation, symétrie, zoom, luminosité, contraste).


2 Statistiques de collecte (avant nettoyage)

2.1 Nombre d'images collectées par espèce

TABLE 1 – Résultats du scraping par espèce

Espèce	URLs trouvées	Cible	Collectées	Taux
Hibou grand-duc	105	100	87	87 %
Flamant rose	139	100	100	100 %
Martin-pêcheur	115	100	100	100 %
Cygne tuberculé	70	100	68	68 %
Pic vert	138	100	100	100 %
Total	567	500	455	91 %

2.2 Visualisation — Images collectées par espèce




3 Statistiques de nettoyage

3.1 Tableau récapitulatif par espèce

TABLE 2 – Résultats du nettoyage par espèce et par motif

Espèce	Avant	Corrompues	Taille	Doublons	Filigranes	Total supprimé	Restantes
Hibou grand-duc	87	0	0	0	14	14	67 (77 %)
Flamant rose	100	0	0	2	8	10	84 (84 %)
Martin pêcheur	100	0	0	0	5	5	93 (93 %)
Cygne tuberculé	68	0	0	0	12	12	53 (78 %)
Pic vert	100	0	0	1	20	21	78 (78 %)
Total	455	0	0	3	59	62	375

3.2 Répartition des suppressions par motif




Observation

Les filigranes constituent la cause principale de suppression (**95,2 %** des images éliminées). Aucune image corrompue n’a été détectée, ce qui témoigne d’un téléchargement robuste.

3.3 Visualisation — Suppressions par espèce et motif

Détail des suppressions par espèce



4 Prétraitement et augmentation

4.1 Pipeline de prétraitement

Chaque image nettoyée est soumise au pipeline suivant :

1. **Conversion RGB** : uniformisation des canaux (suppression des modes RGBA, L, P...).
2. **Redimensionnement** : 224×224 pixels (filtre LANCZOS).
3. **Normalisation** : division par 255, valeurs dans $[0, 1]$.
4. **Sauvegarde JPEG** (qualité 95 %).

4.2 Stratégie d'augmentation

Cinq variantes sont générées par image originale, couvrant :


- Rotation aléatoire dans $[-15^\circ, +15^\circ]$
- Symétrie horizontale (probabilité 50 %)
- Zoom centré aléatoire ($f \in [0.9, 1.1]$)
- Ajustement de luminosité ($\times [0.8, 1.2]$)
- Ajustement de contraste ($\times [0.8, 1.2]$)

TABLE 3 – Images disponibles après prétraitement et augmentation

Espèce	Finales	Facteur	Après augmentation
Hibou grand-duc	67	$\times 6$	402
Flamant rose	84	$\times 6$	504
Martin-pêcheur	93	$\times 6$	558
Cygne tuberculé	53	$\times 6$	318
Pic vert	78	$\times 6$	468
Total	375	$\times 6$	2 250

4.3 Nombre d'images après augmentation

4.4 Visualisation — Avant/après augmentation




5 Répartition finale Train / Validation / Test

Une répartition classique 70 % / 15 % / 15 % est appliquée sur le jeu augmenté.

TABLE 4 – Répartition train/val/test par espèce

Espèce	Total	Train (70 %)	Val (15 %)	Test (15 %)
Hibou grand-duc	402	281	60	61
Flamant rose	504	353	75	76
Martin-pêcheur	558	391	83	84
Cygne tuberculé	318	223	47	48
Pic vert	468	328	70	70
Total	2 250	1 576	335	339



6 Analyse critique des biais potentiels

6.1 Origine géographique des images

Les images ont été collectées via **Bing Images** sans restriction géographique explicite. Cependant, plusieurs biais sont probables :

- Les résultats Bing sont influencés par la langue de la requête (requêtes en **français**). Les images proviennent donc majoritairement de sites européens francophones (France, Belgique, Suisse).
- Le Hibou grand-duc et le Martin-pêcheur étant des espèces emblématiques en Europe de l'Ouest, leurs représentations reflètent principalement cet habitat.
- Le Flamant rose (présent aussi en Afrique et en Asie) pourrait être sous-représenté dans des contextes géographiques hors d'Europe.

Risque identifié

Un modèle entraîné sur ce dataset pourrait être moins performant sur des spécimens photographiés hors d'Europe (sous-espèces, colorations différentes, arrière-plans exotiques).

6.2 Diversité des conditions de prise de vue

La diversité des images Bing est *a priori* plus élevée que celle d'un dataset photographié par une seule équipe, mais certains angles morts restent probables :

- **Saisons** : les oiseaux photographiés en plumage nuptial sont surreprésentés (plus esthétiques, donc plus partagés en ligne).
- **Angles** : les poses de profil ou de 3/4 dominant ; les vues en plein vol ou vues du dessus sont plus rares.
- **Arrière-plans** : les fonds naturels dominant, mais les images de volières ou de zoos peuvent introduire du bruit.
- **Éclairages** : les conditions de faible luminosité (crépuscule, nuit) sont quasi absentes pour les espèces diurnes.

6.3 Disponibilité relative des espèces

TABLE 5 – Facilité de collecte comparée par espèce

Espèce	URLs / Collectées	Commentaire
Flamant rose	139 / 100	Très iconique, abondant en ligne
Pic vert	138 / 100	Commun, nombreux sites naturalistes
Martin-pêcheur	115 / 100	Populaire en photographie animalière
Hibou grand-duc	105 / 87	Espèce nocturne, photos rares
Cygne tuberculé	70 / 68	Moins recherché ; beaucoup de filigranes

6.4 Biais de confirmation

Le scraping par mot-clé produit un **bias de saillance** : les images les mieux classées sont les plus représentatives (bec visible, couleurs vives, fond épuré). Les individus juvéniles, en mue, ou partiellement cachés par la végétation sont systématiquement sous-représentés.

Ce phénomène est amplifié par :

- la popularité des photos de parc/zoo sur les réseaux sociaux ;
- l'algorithme de Bing qui favorise les images les plus cliquées.

7 Respect des droits et aspects légaux

7.1 Sources des images

Les images ont été téléchargées depuis des URLs publiquement indexées par Bing, incluant (liste non exhaustive d'après les logs) :

- [wikimedia.org](https://www.wikimedia.org) — licences Creative Commons (CC-BY, CC-BY-SA)
- [flickr.com](https://www.flickr.com) — droits variables (All Rights Reserved à CC0)
- [fotocommunity.com](https://www.fotocommunity.com) — droits réservés (403 majoritairement rejetés)
- [istockphoto.com](https://www.istockphoto.com) — images sous licence commerciale (rejetées : HTTP 400/403)
- [animalia.bio](https://www.animalia.bio), [les-oiseaux.com](https://www.les-oiseaux.com) — droits réservés (rejetées)
- [facebook \(fbsbx.com\)](https://www.facebook.com) — droits réservés
- Sites de presse ([actu.fr](https://www.actu.fr), [rtbf.be](https://www.rtbf.be)) — droits réservés

7.2 Cadre légal applicable

Avertissement

Ce dataset est utilisé uniquement dans un cadre académique et pédagogique. Les images collectées restent la propriété de leurs auteurs respectifs.

Quelques points légaux importants :

1. **Droits d’auteur** : toute image publiée sur Internet est protégée automatiquement par le droit d’auteur.
2. **Usage académique** : les images sont utilisées uniquement pour l’apprentissage, la recherche et l’expérimentation non commerciale.
3. **Moteurs de recherche** : les résultats affichés par Bing ou Google ne donnent pas le droit de réutiliser librement les images.
4. **Scraping** : la collecte automatique doit respecter les conditions d’utilisation et les règles des sites web concernés.
5. **Protection des données** : le dataset ne contient pas volontairement d’informations personnelles sensibles.

8 Synthèse

TABLE 6 – Tableau de synthèse global du pipeline

Étape	Nombre d’images
Collectées (scraping)	455
Supprimées (nettoyage)	62 (13,6 %)
dont filigranes	59
dont doublons	3
Après nettoyage	375
Après prétraitement (finales)	375
Après augmentation ($\times 6$)	2 250
Jeu d’entraînement (70 %)	1 576
Jeu de validation (15 %)	335
Jeu de test (15 %)	339

Conclusion

Le dataset final contient **2 250 images** réparties équitablement entre 5 espèces et 3 sous-ensembles. Le pipeline automatisé (scraping → nettoyage → prétraitement → augmentation) est reproductible et documenté. Les principaux biais identifiés (surreprésentation de l’Europe de l’Ouest, poses saillantes, plumage nuptial) devront être corrigés lors d’une éventuelle mise en production par l’intégration de sources ouvertes et diversifiées géographiquement.