
Collecte et Préparation d'un Dataset d'Images oiseaux

Rapport

Méthodologie, Statistiques, Limites & Éthique

Repository : github.com/souhayle98/projet_scraping2

Branches : main (production) dev (développement)

Date : 16 mai 2026

Scraping → Nettoyage < Prétraitement < Augmentation > Division

Pipeline complet — de la collecte à la préparation finale

Table des matières

1	Introduction et Contexte	2
2	Méthodologie Complète	2
2.1	Étape 1 — Collecte des données (Scraping)	2
2.2	Étape 2 — Nettoyage (<code>nettoyage.py</code>)	2
2.3	Étape 3 — Prétraitement (<code>pretraitement.py</code>)	3
2.4	Étape 4 — Augmentation (<code>augmentation.py</code>)	3
2.5	Stratégie d'augmentation	3
2.6	Étape 5 — Division du dataset (<code>division_dataset.py</code>)	3
3	Difficultés Rencontrées et Solutions Apportées	3
4	Statistiques Détaillées du Dataset	4
4.1	Vue d'ensemble	4
4.2	Répartition par classe	4
4.3	Répartition Train / Validation / Test	5
4.4	Résumé des dimensions	5
5	Analyse Critique des Limites et Biais du Dataset	5
5.1	Biais de représentativité	5
5.2	Biais de qualité variable	5
5.3	Déséquilibre résiduel de classes	5
5.4	Évolution temporelle	6
5.5	Absence d'annotations humaines	6
6	Réflexion Éthique	6
6.1	Respect des conditions d'utilisation	6
6.2	Droits d'auteur et licences	6
6.3	Biais algorithmiques et justice	6
6.4	Transparence et reproductibilité	7
7	Conclusion	7

1. Introduction et Contexte

Ce rapport présente la démarche complète de construction d'un dataset d'images destiné à l'entraînement d'un modèle de vision par ordinateur. Le projet couvre l'intégralité du pipeline : depuis la collecte automatisée des données brutes jusqu'à la mise en forme du dataset final prêt pour l'apprentissage.

Objectif du projet

Constituer un dataset d'images propre, équilibré et annoté en respectant les bonnes pratiques de l'ingénierie des données et les principes éthiques de collecte.

Technologies utilisées :

- **Scraping** : Python, requests, BeautifulSoup, Selenium
- **Traitement image** : Pillow, OpenCV
- **Analyse** : pandas, matplotlib, scikit-learn
- **Versioning** : Git / GitHub (main + dev)

2. Méthodologie Complète

2.1. Étape 1 — Collecte des données (Scraping)

Le script `Scraping/scrapper_oi.py` réalise la collecte automatisée d'images depuis des sources web publiques. Deux approches complémentaires ont été combinées :

- **Scraping statique** via `requests` + `BeautifulSoup` pour les pages HTML standards ;
- **Scraping dynamique** via `Selenium` pour les sites à rendu JavaScript (chargement différé, pagination infinie).

Un système de journalisation est intégré (`rapports/scraping.log`) pour tracer chaque requête, horodater les sessions et identifier les erreurs réseau. Un délai aléatoire entre les requêtes (1–3 secondes) a été appliqué pour limiter la charge serveur et respecter les bonnes pratiques.

2.2. Étape 2 — Nettoyage (`nettoyage.py`)

Le nettoyage constitue une étape critique pour garantir la qualité du dataset :

1. **Détection des doublons** par hachage MD5 des fichiers image ;
2. **Vérification d'intégrité** : ouverture systématique avec `Pillow` pour détecter les fichiers corrompus ou tronqués ;
3. **Filtrage dimensionnel** : suppression des images trop petites (résolution inférieure à 64×64 px) ;
4. **Vérification du format** : conservation des formats JPEG, PNG et WebP uniquement.

Les opérations sont consignées dans `rapports/nettoyage.log`.

2.3. Étape 3 — Prétraitement (`pretraitement.py`)

Toutes les images sont standardisées avant l'entraînement :

- Redimensionnement uniforme à **224×224 pixels** (standard ResNet/VGG) ;
- Conversion en espace colorimétrique **RGB** ;
- Normalisation des valeurs pixel dans $[0, 1]$;
- Conversion en NumPy `array` et sauvegarde au format `.npy`.

2.4. Étape 4 — Augmentation (`augmentation.py`)

Pour compenser les déséquilibres de classes et enrichir la variabilité :

2.5. Stratégie d'augmentation


Cinq variantes sont générées par image originale, couvrant :

- Rotation aléatoire dans $[-15, +15]$
- Symétrie horizontale (probabilité 50 %)
- Zoom centré aléatoire ($f \in [0.9, 1.1]$)
- Ajustement de luminosité ($\times [0.8, 1.2]$)
- Ajustement de contraste ($\times [0.8, 1.2]$)

TABLE 1 – Transformations appliquées lors de l'augmentation

2.6. Étape 5 — Division du dataset (`division_dataset.py`)

Le dataset est divisé de manière stratifiée (conservation des proportions de classes) :



La reproductibilité est assurée par la fixation d'une graine aléatoire (`random_state=42`).

3. Difficultés Rencontrées et Solutions Apportées

Principaux obstacles identifiés

1. **Blocage des requêtes HTTP** (code 403/429) : résolu par rotation d'agents utilisateur et délais adaptatifs ;
2. **Contenu dynamique JavaScript** : résolu par l'intégration de Selenium avec `WebDriverWait` ;
3. **Doublons inter-sources** : résolu par hachage MD5 global (toutes sources confondues) ;
4. **Déséquilibre de classes** : compensé par sur-augmentation ciblée des classes minoritaires ;
5. **Images corrompues à la lecture** : gestion par blocs `try/except` avec journalisation.

La **pagination infinie** (scroll automatique) a nécessité une stratégie spécifique : simulation du défilement via JavaScript exécuté par Selenium, avec détection de la condition de fin de page par comparaison de hauteur DOM.


4. Statistiques Détaillées du Dataset

4.1. Vue d'ensemble

TABLE 2 – Tableau de synthèse global du pipeline

Étape	Nombre d'images
Collectées (scraping)	455
Supprimées (nettoyage)	62 (13,6 %)
dont filigranes	59
dont doublons	3
Après nettoyage	375
Après prétraitement (finales)	375
Après augmentation ($\times 6$)	2 250
Jeu d'entraînement (70 %)	1 576
Jeu de validation (15 %)	335
Jeu de test (15 %)	339

4.2. Répartition par classe



4.3. Répartition Train / Validation / Test

Une répartition classique 70 % / 15 % / 15 % est appliquée sur le jeu augmenté.

TABLE 3 – Répartition train/val/test par espèce

Espèce	Total	Train (70 %)	Val (15 %)	Test (15 %)
Hibou grand-duc	402	281	60	61
Flamant rose	504	353	75	76
Martin-pêcheur	558	391	83	84
Cygne tuberculé	318	223	47	48
Pic vert	468	328	70	70
Total	2 250	1 576	335	339

4.4. Résumé des dimensions

Indicateur	Avant prétraitement	Après prétraitement
Résolution min.	64 × 64 px	224 × 224 px
Résolution max.	4096 × 3072 px	224 × 224 px
Résolution médiane	512 × 384 px	224 × 224 px
Format colorimétrique	RGB / RGBA / L	RGB
Taille moyenne fichier	387 Ko	42 Ko

TABLE 4 – Statistiques dimensionnelles des images

5. Analyse Critique des Limites et Biais du Dataset

5.1. Biais de représentativité

La collecte automatisée par mots-clés introduit un **biais de sélection** : les images récupérées reflètent les représentations dominantes sur les moteurs de recherche, qui peuvent surreprésenter certains styles visuels, contextes géographiques ou groupes démographiques au détriment d'autres.

5.2. Biais de qualité variable

Les sources hétérogènes (sites professionnels, réseaux sociaux, encyclopédies) génèrent une variance importante en termes de résolution, d'éclairage et de composition. Malgré le prétraitement, cette hétérogénéité peut affecter la généralisation du modèle.

5.3. Déséquilibre résiduel de classes

Même après augmentation, un déséquilibre persiste entre les classes (rapport max/min $\approx 1,76$). Des techniques complémentaires — telles que le sur-échantillonnage SMOTE ou la pondération des classes dans la fonction de perte — seraient recommandées lors de la phase d'entraînement.

5.4. Évolution temporelle

Le dataset représente un *instantané* des données disponibles au moment de la collecte. Les modèles entraînés sur ce corpus pourraient souffrir d'une dérive conceptuelle (*concept drift*) si déployés dans un contexte où les données évoluent rapidement.

5.5. Absence d'annotations humaines

Les étiquettes sont dérivées automatiquement (mots-clés, métadonnées, structure des dossiers). Une validation humaine d'un sous-ensemble aléatoire serait nécessaire pour estimer le taux d'erreur d'annotation.

Recommandations

- Intégrer un audit humain sur 5–10% des images ;
- Documenter précisément les sources et dates de collecte ;
- Réexaminer périodiquement la distribution du dataset.

6. Réflexion Éthique

Principes éthiques appliqués

La collecte et l'utilisation d'images issues du web soulèvent des questions fondamentales que ce projet a cherché à adresser de manière rigoureuse.

6.1. Respect des conditions d'utilisation

Avant toute collecte, le fichier `robots.txt` de chaque source a été consulté et respecté. Les sites explicitement interdisant le scraping automatisé ont été exclus du périmètre. Les délais entre requêtes limitent l'impact sur les serveurs cibles.

6.2. Droits d'auteur et licences

La majorité des images collectées est soumise à des droits d'auteur. Ce dataset est strictement réservé à un usage académique et non commercial, conformément à la doctrine du *fair use* dans le cadre de la recherche. Il ne doit pas être redistribué publiquement sans vérification préalable des licences image par image.

- Informer les personnes concernées ou obtenir leur consentement ;
- Flouter ou anonymiser les visages si utilisé hors contexte artistique/documentaire ;
- Respecter le droit à l'oubli en cas de demande de suppression.

6.3. Biais algorithmiques et justice

Un modèle entraîné sur un dataset biaisé perpétue et amplifie ces biais. Il est essentiel d'**auditer les performances par sous-groupe** (genre, âge, origine géographique) et de documenter les limitations dans toute publication ou déploiement du modèle résultant.

6.4. Transparence et reproductibilité

L'ensemble du pipeline est versionné sur GitHub, les logs de collecte sont archivés et ce rapport documente les choix méthodologiques. Cette traçabilité est une exigence minimale d'une démarche scientifique responsable.

7. Conclusion

Ce projet a permis de mettre en œuvre un pipeline complet et reproductible de préparation de données images. Les principales contributions sont :

- Un dataset normalisées, augmentées et divisées en ensembles d'entraînement, de validation et de test ;
- Un pipeline modulaire, versionné et entièrement documenté ;
- Une réflexion approfondie sur les biais et les implications éthiques.

Les limites identifiées — biais de représentativité, déséquilibre résiduel, absence d'annotation humaine — constituent autant de pistes d'amélioration pour les versions futures du dataset. L'intégration d'un audit humain et l'élargissement des sources de collecte permettraient de renforcer significativement la qualité et la fiabilité du corpus.

Repository : github.com/souhayle98/projet_scraping2

Logs : `rapports/scraping.log` | `rapports/nettoyage.log`